Training neural networks with regularization

Anton Antonov MathematicaVsR at GitHub May 2018

Introduction

This notebook is part of the MathematicaVsR at GitHub project "DeepLearningExamples".

This notebook has code that corresponds to code in the book "Deep learning with R" by F. Chollet and J. J. Allaire. See the GitHub repository: https://github.com/jjallaire/deep-learning-with-r-notebooks; specifically the notebook "Overfitting and underfitting".

In many ways that R notebook has content similar to WL's "Training Neural Networks with Regularization".

The R notebook "Overfitting and underfitting" discusses the following possible remedies of overfitting: smaller network, weight regularization, and adding of a dropout layer.

The WL "Training Neural Networks with Regularization" notebook discusses: early stopping of network training, weight decay, and adding of a dropout layer.

The goal of this notebook is to compare the R-Keras and WL-MXNet neural network frameworks in a more obvious way with simple data and networks.

Get code

Here we load a package with utilities:

| Import["https://raw.githubusercontent.com/antononcube/MathematicaForPrediction/master/MathematicaForPredictionUtilities.m"

Get data

As seen in the tutorial page "Training Neural Networks with Regularization".

```
\label{eq:local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_
```

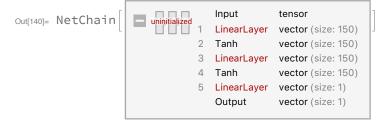
Out[138]= **31**

-0.2

Overfitting

Create a multilayer perceptron with a large number of hidden units:





Train the net for 10 seconds:

In[141]:= results1 = NetTrain[net, data, All, TimeGoal → 10]



Despite the noise in the data, the final loss is very low:

$\label{eq:ln[142]:=} $$ \inf[142]:= $$ results1["FinalRoundLoss"]$$ Out[142]= $1.81048\times10^{-7}$$$

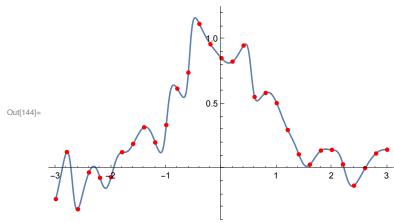
The resulting net overfits the data, learning the noise in addition to the underlying function. To see this, we plot the function learned by the net alongside the original data.

Obtain the net from the NetTrainResultsObject:

In[143]:= overfitNet = results1["TrainedNet"]



In[144]:= Show[Plot[overfitNet[x], {x, -3, 3}], plot]



Smaller network

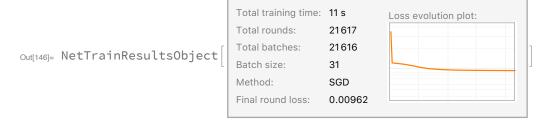
Make smaller net and train for same time.

In[145]:= net2 = NetChain[{3, Tanh, 3, Tanh, 1}]



Train the net for 10 seconds:

In[146]:= results2 = NetTrain[net2, data, All, TimeGoal → 10]

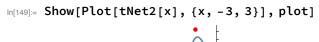


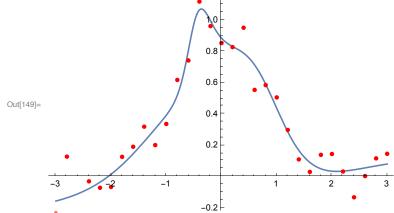
In[147]:= results2["FinalRoundLoss"]

Out[147]= 0.00962029

In[148]:= tNet2 = results2["TrainedNet"]







Weight decay

In[150]:= results3 = NetTrain[net, data, All, Method → {"SGD", "L2Regularization" → 0.01}]

Out[150]= NetTrainResultsObject [

Total training time: 4.5 s

Total rounds: 10 000

Total batches: 10 000

Batch size: 31

Method: SGD

Final round loss: 0.0138

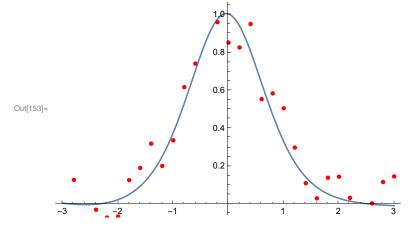
In[151]:= results3["FinalRoundLoss"]

Out[151]= 0.0137857

In[152]:= tNet4 = results3["TrainedNet"]



In[153]:= Show[Plot[tNet3[x], {x, -3, 3}], plot]



Dropout

Add dropout layer.

In[160]:= net4 = NetChain[{150, DropoutLayer[0.2], Tanh, 150, Tanh, 1}]

uninitialized Input port:
Output port: Out[160]= NetChain vector (size: 1) Number of layers: 6

Train the net for 10 seconds:

In[161]:= results3 = NetTrain[net4, data, All, TimeGoal → 10]

Total training time: 11 s Loss evolution plot: Total rounds: 17594 17 593 Total batches: Out[161]= NetTrainResultsObject Batch size: 31 Method: ADAM Final round loss: 0.00416

In[162]:= results4["FinalRoundLoss"]

Out[162]= 0.0174739

In[163]:= tNet4 = results4["TrainedNet"]

Out[163]= NetChain Output port: scalar Number of layers: 5

ln[164]:= Show[Plot[tNet4[x], {x, -3, 3}], plot]

